

Baraj Doluluk Oranı Kestirimi

Zehra An

Bilişim Sistemleri Mühendisliği
Teknoloji Fakültesi/ Kocaeli Üniversitesi
201307033@kocaeli.edu.tr

Özet

Baraj su seviyesi tahmini, özellikle su kıtlığı riski taşıyan bölgelerde su kaynaklarının etkin yönetimi açısından büyük önem taşımaktadır. Bu çalışmada, Ömerli Barajı'nın su seviyesini tahmin etmek için Informer, Reformer, Autoformer, Temporal Fusion Transformer (TFT) ve Vanilla LSTM gibi derin öğrenme modellerinin performansı incelenmiştir. Kullanılan veri seti, 1 Ocak 2011 ile 18 Şubat 2024 tarihleri arasındaki günlük baraj doluluk oranı, yağış miktarı ve su tüketimi verilerini içermektedir. Model performansını artırmak amacıyla özellik mühendisliği, normalizasyon ve sekans oluşturma gibi çeşitli veri ön işleme teknikleri uygulanmıştır. Modeller, Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE), Ortalama Mutlak Hata (MAE), Ortalama Mutlak Yüzde Hatası (MAPE) ve R^2 skoru gibi standart metriklerle değerlendirilmiştir..

Keywords— Baraj su seviyesi tahmini, zaman serisi analizi, derin öğrenme, transformatör tabanlı modeller, Informer, Reformer, Autoformer, Temporal Fusion Transformer (TFT), su kaynakları yönetimi..

Abstract

Reservoir water level prediction plays a crucial role in efficient water resource management, especially in regions facing water scarcity risks. In this study, the performance of deep learning models, including Informer, Reformer, Autoformer, Temporal Fusion Transformer (TFT), and Vanilla LSTM, is examined for forecasting the water level of the Ömerli Reservoir. The dataset consists of daily reservoir occupancy rates, precipitation levels, and water consumption records from January 1, 2011, to February 18, 2024. Various data preprocessing techniques, such as feature engineering, normalization, and sequence generation, are applied to enhance model performance. The models are evaluated using standard metrics, including Mean Squared Error (MSE), Root Mean Squared Error (RMSE), Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE), and R^2 score.

1. Giriş

Dünya genelinde su kaynaklarının sürdürülebilir yönetimi giderek daha büyük bir önem kazanmaktadır. Artan nüfus, sanayileşme ve iklim değişikliği gibi faktörler, su talebinin artmasına ve su kaynaklarının tükenme riskine yol açmaktadır. Bu nedenle, özellikle büyük şehirlerde su rezervlerinin doğru yönetimi için baraj su seviyesi tahmini kritik bir rol oynamaktadır.

Geleneksel su seviyesi tahmin yöntemleri genellikle istatistiksel analizlere ve fizik tabanlı modellere dayanmaktadır. Ancak, bu yaklaşımlar genellikle karmaşık meteorolojik ve hidrolojik süreçleri yeterince temsil edemekte ve uzun vadeli tahminlerde düşük doğruluk sergilemektedir. Son yıllarda, derin öğrenme tabanlı zaman serisi tahmin modelleri, büyük veri setlerinden karmaşık ilişkileri öğrenme yetenekleri sayesinde bu alanda önemli başarılar elde etmiştir. Özellikle transformatör tabanlı modeller, sekans verilerindeki uzun vadeli bağımlılıkları daha iyi yakalayarak geleneksel yöntemlere kıyasla daha başarılı sonuçlar sunmaktadır.

Bu çalışmada, Ömerli Barajı'nın su seviyesini tahmin etmek için Informer, Reformer, Autoformer, Temporal Fusion Transformer (TFT) ve Vanilla LSTM gibi derin öğrenme modellerinin performansı karşılaştırılmıştır. 1 Ocak 2011 ile 18 Şubat 2024 tarihleri arasındaki günlük baraj doluluk oranı, yağış miktarı ve su tüketimi verileri kullanılarak bir tahmin modeli oluşturulmuştur. Çalışmanın temel amacı, farklı derin öğrenme modellerinin performansını değerlendirerek en yüksek doğruluğa sahip yöntemi belirlemektir.

2. Önerilen Model

Bu bölümde, baraj doluluk oranı tahmini için kullanılan veri seti, derin öğrenme modelleri ve önerilen model çerçevesi detaylı olarak ele alınmaktadır.

2.1. Veri Elde Etme

Bu çalışmada kullanılan veri seti, 1 Ocak 2011 - 18 Şubat 2024 tarihleri arasındaki günlük baraj doluluk oranı, yağış

miktarı ve su tüketimi verilerini içermektedir. Veriler, ilgili resmi kurumların sağladığı açık veri kaynaklarından ve meteorolojik ölçümlerden derlenmiştir.

Veri setinde, baraj doluluk oranı bağımlı değişken olarak belirlenirken, yağış miktarı ve su tüketimi gibi değişkenler bağımsız değişkenler olarak kullanılmıştır. Zaman serisi verisinin doğasına uygun olarak, tarih bilgisi yıl, ay, gün bileşenlerine ayrılmış ve ayrıca mevsimsel etkileri dikkate almak amacıyla bir mevsim değişkeni oluşturulmuştur.

Bunun yanı sıra, kısa vadeli eğilimleri yakalamak için toplam yağış miktarı, 7 günlük kümülatif yağış ve gecikmeli (lag) yağış değişkenleri türetilmiştir. Bu özellik mühendisliği adımları, modellerin gelecekteki baraj doluluk oranını daha iyi tahmin edebilmesine yardımcı olmak amacıyla gerçekleştirilmiştir.

Elde edilen veri seti, eksik ve hatalı veriler açısından incelenmiş, eksik veriler uygun yöntemlerle doldurulmuş veya temizlenmiştir. Son olarak, model eğitimi öncesinde tüm değişkenler min-max normalizasyonu uygulanarak ölçeklendirilmiş ve zaman serisi tahmini için uygun veri formatına dönüştürülmüştür..

2.2. Transformatör Tabanlı Modeller

Son yıllarda, zaman serisi tahmininde derin öğrenme modellerinin etkinliği giderek artmış ve özellikle transformatör tabanlı yaklaşımlar büyük ilgi görmüştür. Geleneksel LSTM ve GRU gibi RNN tabanlı modeller, uzun bağımlılıkları öğrenme konusunda bazı sınırlamalara sahipken, transformatör mimarileri kendi kendine dikkat (self-attention) mekanizması sayesinde uzun vadeli ilişkileri daha verimli bir şekilde modelleyebilmektedir.

Bu çalışmada, Informer, Reformer, Autoformer ve Temporal Fusion Transformer (TFT) gibi çeşitli transformatör tabanlı modeller kullanılarak baraj doluluk oranı tahmin edilmiştir.

2.2.1. Informer

Informer modeli, uzun vadeli zaman serisi tahminlerinde verimli ve ölçeklenebilir bir yaklaşım sunan transformatör tabanlı bir mimaridir. Klasik transformatörlerin hesaplama maliyetini düşürmek için geliştirilen Informer, ProbSparse Self-Attention mekanizmasını kullanarak dikkate alınan bilgi yoğunluklu dikkat skorlarını seçer ve gereksiz hesaplamaları azaltır. Böylece, geleneksel $O(L^2d)$ zaman karmaşıklığı yerine $O(L\log L)$ gibi daha verimli bir yapı elde edilir.

Model, çoklu başlı dikkat (Multi-Head Attention) mekanizması sayesinde farklı zaman ölçeklerinde ilişkileri yakalayarak uzun vadeli bağımlılıkları daha iyi öğrenir. Informer, ayrıca genişletilmiş besleme ileri ağları (Feedforward Layers) ile dikkat mekanizmasının çıktılarını güçlendirir ve modelin doğruluk seviyesini artırır. Özetle dönüştürme katmanları, giriş verilerini belirli bir gömme (embedding) boyutuna çevirerek modelin veriyi daha iyi işlemesini sağlar.

Informer modeli, özellikle uzun sekanslarda tahmin doğruluğunu artırırken hesaplama maliyetini düşürmesiyle öne çıkar. Klasik transformatör modellerinin işlem gücü

gereksinimlerini azaltarak büyük ölçekli zaman serisi tahmin problemlerinde daha etkili bir performans sunar.

2.2.2. Reformer

Reformer modeli, geleneksel transformatörlerin uzun sekanslardaki hesaplama ve bellek maliyetlerini azaltmak amacıyla geliştirilmiş bir modeldir. Bu model, özellikle Yerel Hassas Dikkat (LSH Attention) ve Geri Çevrilebilir Katmanlar (Reversible Residual Layers) gibi yenilikçi teknikler sayesinde büyük veri kümeleri üzerinde daha verimli çalışabilmektedir.

LSH Attention, dikkat mekanizmasındaki hesaplama yükünü azaltmak için tüm öğeler arasındaki benzerlik hesaplaması yerine hashing yöntemini kullanarak benzer öğeleri gruplayarak dikkati uygular. Böylece, geleneksel transformatörlerin $O(L^2)$ olan hesaplama karmaşıklığı $O(L\log L)$ seviyesine düşürülmüştür. Bunun yanında, geri çevrilebilir katmanlar sayesinde modelin bellek kullanımı optimize edilerek daha büyük sekans uzunluklarında işlem yapabilmesi sağlanmaktadır.

Bu çalışmada, Reformer modeli kullanılarak Ömerli Barajı'nın doluluk oranı tahmini gerçekleştirilmiştir. Model, 30 günlük giriş verisi olarak 7 günlük ileriye dönük tahminler üretmektedir. Modelin giriş katmanı, veriyi uygun boyuta dönüştürmek için tam bağlantılı bir katmandan geçirilmekte ve ardından ReformerModel ile işlenmektedir. Son katmanda, modelin tahmin yapabilmesi için tam bağlantılı bir çıkış katmanı bulunmaktadır. Modelin eğitimi sırasında Mean Squared Error (MSE) kaybı minimize edilmiş ve optimizasyon için Adam optimizier kullanılmıştır.

Reformer modeli, geleneksel transformatörlerin bellek ve hesaplama sınırlamalarını aşarak uzun vadeli bağımlılıkları daha verimli şekilde öğrenme kapasitesine sahiptir. Bu özellikleri sayesinde zaman serisi tahminlerinde etkili bir model olarak kullanılabilir..

2.2.3. TFT(Nvidia)

Temporal Fusion Transformer (TFT) modeli, zaman serisi tahmini için geliştirilmiş, çok değişkenli verilerle çalışabilen ve uzun vadeli bağımlılıkları öğrenebilen bir derin öğrenme modelidir. Modelin yapısı, Gated Residual Network (GRN), çoklu başlıklı dikkat mekanizması (Multi-Head Attention) ve uzun kısa vadeli bellek (LSTM) katmanları gibi bileşenlerden oluşur.

GRN katmanları, modelin önemli bilgileri vurgulamasını ve gereksiz bilgileri filtrelemesini sağlarken, çoklu başlıklı dikkat mekanizması değişkenler arasındaki etkileşimleri öğrenmeye yardımcı olur. LSTM katmanları ise zaman serisi verilerindeki ardışık bağıntıları yakalamak için kullanılmıştır.

Modelin girişinde, veriler belirli bir gömme (embedding) katmanından geçirilerek temsil gücü artırılmış ve normalleştirilmiştir. Ardından, çok başlıklı dikkat katmanı ile değişkenler arası ilişkiler modellenmiş, GRN katmanları ile ek bilgi işleme gerçekleştirilmiş ve LSTM katmanları ile zaman içindeki bağımlılıklar öğrenilmiştir. Son olarak, tam bağlantılı (dense) bir katman ile tahmin çıktıları üretilmiştir.

TFT modeli, veri içindeki önemli özellikleri dinamik olarak seçebilme yeteneğine sahip olup, karmaşık ve çok değişkenli

zaman serisi tahmin problemlerinde yüksek başarı sağlamaktadır..

2.2.4. Vanilla

Vanilla Transformer modeli, zaman serisi tahmini için standart Transformer yapısını kullanan bir modeldir. Model, girdi verilerini belirli bir boyuta dönüştürerek işleyebilecek hale getirir ve zaman içindeki bağımlıları öğrenerek tahminler üretir. İlk olarak, giriş verisi bir gömme katmanı aracılığıyla belirli bir boyuta eşlenir. Bu adım, modelin zaman serisi verisini daha iyi anlamasını sağlar. Daha sonra, dönüştürülen veriler Transformer Encoder katmanlarına gönderilir. Bu katmanlar, çok başlıklı dikkat mekanizması kullanarak giriş dizisindeki uzun vadeli bağımlılıkları öğrenir. Modelde iki adet Transformer Encoder katmanı bulunmaktadır ve bu katmanlar sayesinde zaman içindeki karmaşık ilişkiler yakalanabilir. Son olarak, Transformer Encoder katmanlarından geçen bilgi tam bağlantılı bir çıkış katmanı ile işlenerek nihai tahminler üretilir.

Vanilla Transformer modeli, uzun vadeli bağımlılıkları etkili bir şekilde öğrenebilmesi ve çok değişkenli zaman serisi tahmini için güçlü bir yapı sunmasıyla öne çıkar. Daha karmaşık ve özelleştirilmiş Transformer tabanlı modellere kıyasla daha sade bir yapıya sahiptir, ancak zaman serisi tahmininde yüksek performans gösterebilir.

2.2.5. Autoformer

Autoformer modeli, zaman serisi tahmini için geliştirilmiş ve özellikle uzun vadeli bağımlılıkları yakalamada etkili bir derin öğrenme modelidir. Model, zaman serisi verisini bileşenlerine ayırarak (trend ve mevsimsellik) öğrenme sürecini iyileştirmeyi amaçlar. Bu süreç, serinin daha anlamlı bileşenlere ayrılmasını sağlar ve modelin zaman içindeki desenleri daha iyi kavramasına yardımcı olur.

Autoformer modelinin temel bileşenlerinden biri Seri Ayırıştırma (Series Decomposition) katmanıdır. Bu katman, giriş zaman serisini trend ve mevsimsel bileşenler olarak ikiye ayırır. Trend bileşeni, uzun vadeli değişimleri yakalarken, mevsimsel bileşen daha kısa vadeli tekrar eden desenleri öğrenir. Bu ayırım, modelin zaman içindeki farklı desenleri daha etkili bir şekilde anlamasına yardımcı olur.

Bir diğer önemli bileşen Otomatik Korelasyon (AutoCorrelation) mekanizmasıdır. Geleneksel dikkat (attention) mekanizmalarının aksine, Autoformer, doğrudan geçmişteki benzer desenleri keşfetmeye odaklanır. Model, dikkat mekanizmasını kullanarak belirli zaman adımlarındaki verileri birbirleriyle ilişkilendirir ve bu bilgileri tahmin sürecine dahil eder.

Autoformer modeli, encoder-decoder mimarisi üzerine inşa edilmiştir. Autoformer Encoder, giriş verisini işleyerek uzun vadeli bağımlılıkları öğrenir ve ilgili bilgileri sıkıştırır. Autoformer Decoder, encoder tarafından işlenen bilgiyi alarak gelecek zaman adımları için tahminler üretir. Encoder ve decoder katmanları, yukarıda bahsedilen seri ayırıştırma ve otomatik korelasyon mekanizmalarını kullanarak zaman serisinin farklı bileşenlerini öğrenir ve tahmin sürecine dahil eder.

Modelin çıktısı, eğitilmiş ağırlıklarla birlikte tahmin sürecinden geçirilerek üretilir. Son olarak, tam bağlantılı bir katman (dense layer) kullanılarak modelin nihai tahminleri oluşturulur. Autoformer, zaman serisi tahmini için geleneksel Transformer mimarisine kıyasla daha verimli bir yapı sunar ve uzun vadeli tahminlerde daha doğru sonuçlar elde edilmesini sağlar.

2.3. Önerilen Çerçeve

Bu çalışmada, Ömerli Barajı'nın su seviyesi tahmini için önerilen model çerçevesi, derin öğrenme tabanlı transformer modellerinin gücünden faydalanarak zaman serisi verilerini etkili bir şekilde öğrenmeyi hedeflemektedir. Model, baraj doluluk oranını tahmin etmek için kullanılan çeşitli bağımsız değişkenlerin (yağış miktarı, su tüketimi vb.) karmaşık ilişkilerini öğrenmek ve gelecekteki değerleri doğru bir şekilde tahmin edebilmek için optimize edilmiştir. Önerilen model, belirli bir işlem akışına dayanır.

İlk olarak, veri hazırlığı aşamasında baraj doluluk oranı, yağış miktarı ve su tüketimi gibi değişkenleri içeren veri seti kullanılmıştır. Zaman serisi verilerinin doğru bir şekilde modellenebilmesi için tüm veriler normalizasyon ve eksik veri işlemleriyle temizlenmiş ve uygun bir formata dönüştürülmüştür.

Ardından, özellik mühendisliği aşamasında zaman serisi tahmininde önemli olan kısa vadeli ve uzun vadeli desenlerin öğrenilmesini sağlamak amacıyla çeşitli teknikler uygulanmıştır. Bu teknikler arasında yağış miktarları ve gecikmeli veriler gibi yeni değişkenlerin türetilmesi yer almaktadır.

Model seçimi ve eğitimi aşamasında, farklı transformer tabanlı modeller (Informer, Reformer, Autoformer, Temporal Fusion Transformer (TFT), Vanilla LSTM) kullanılarak karşılaştırmalı bir analiz yapılmış ve her modelin baraj doluluk oranı tahmin performansı değerlendirilmiştir. Her model, tarihsel verilere dayalı olarak gelecekteki su seviyelerini tahmin etmek için eğitilmiştir.

Model değerlendirme ve karşılaştırma aşamasında ise, her modelin tahmin doğruluğu MSE, RMSE, MAE, MAPE gibi standart metriklerle değerlendirilmiştir. Bu adımda, modellerin birbirleriyle karşılaştırılması yapılmış ve en uygun tahmin modelinin seçilmesi sağlanmıştır.

Son olarak, sonuçların yorumlanması aşamasında tahmin edilen sonuçlar analiz edilerek hangi modelin en başarılı tahmin performansını gösterdiği belirlenmiştir. Ayrıca elde edilen sonuçlar doğrultusunda önerilerde bulunulmuştur.

Bu çerçevede, derin öğrenme tabanlı modellerin kullanımı, özellikle uzun vadeli bağımlılıkları öğrenme ve karmaşık zaman serisi ilişkilerini modelleme konusunda önemli avantajlar sunmaktadır. Önerilen model çerçevesi, Ömerli Barajı'nın su seviyesi tahmin doğruluğunu artırmayı hedeflemekte ve gelecekteki su kaynakları yönetimi için değerli bir araç olabilir..

3. Sonuçlar

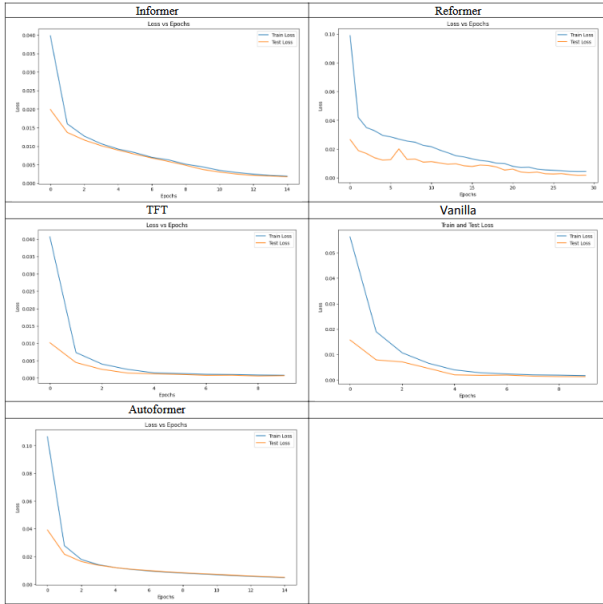
Bu çalışma, Ömerli Barajı'nın su seviyesi tahmini üzerine odaklanarak, çeşitli transformer tabanlı modelleri değerlendirmiştir. Kullanılan modeller arasında Informer, Reformer, Autoformer, Temporal Fusion Transformer (TFT) ve Vanilla LSTM yer almaktadır. Aşağıda, her bir modelin baraj doluluk oranı tahmini performansına dair elde edilen sonuçlar yer almaktadır.

	Informer	Reformer	Autoformer	TFT	Vanilla
Training Time	2.15s	3.40s	167.88s	101.74s	16.69s
Inference Time	0.20s	0.15s	2.45	2.29s	1.01s
Epoch	15	30	15	10	10

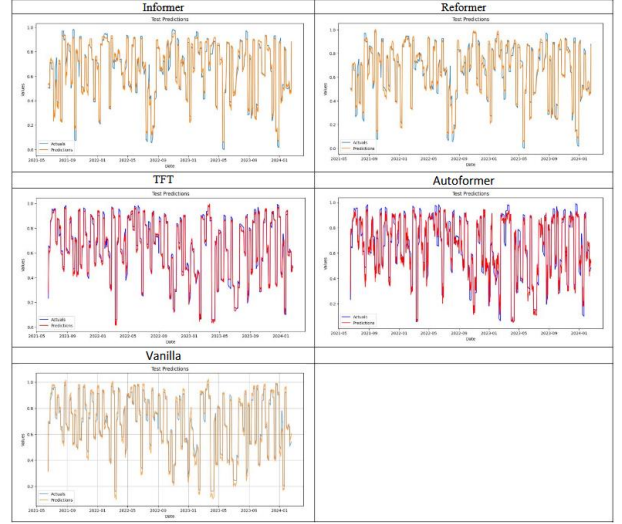
Şekil 1 Modellerin eğitim zamanı ve çıkarım zamanı karşılaştırması

	Informer	Reformer	Autoformer	TFT	Vanilla
MSE	0.0014	0.0014	0.0040	0.0006	0.0010
RMSE	0.0373	0.0379	0.0631	0.0238	0.0318
MAE	0.0285	0.0293	0.0475	0.0185	0.0250
MAPE	0.0481	0.0523	0.0849	0.0307	0.0421
R ²	0.9709	0.9699	0.9166	0.9882	0.9788

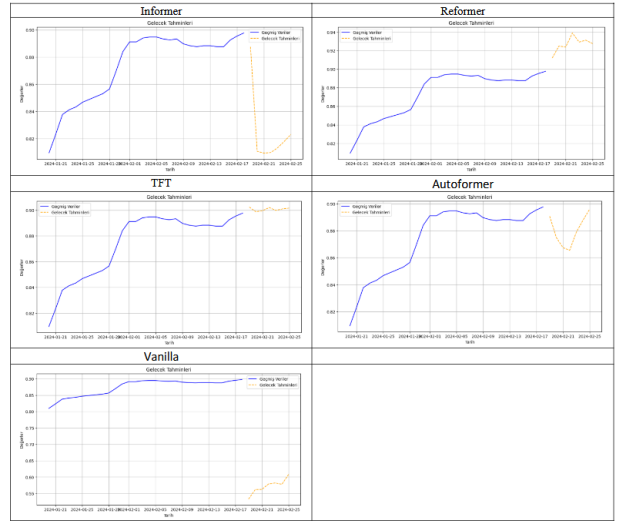
Şekil 2 Modellerin performans metriklerinin karşılaştırması



Şekil 3 Modellerin epoch size ve loss grafikleri



Şekil 4 Modellerin test veri seti üzerinde yaptıkları tahminler



Şekil 5 Modellerin gelecek zaman için tahminleri

4. Colab Linkleri

Reformer:

<https://colab.research.google.com/drive/1ZXtVm-AyTtyTSA7vQRdZKNhBrOBNYHOi?usp=sharing>

Informer:

<https://colab.research.google.com/drive/1iCbwdSMMIGnenhP-R7kk6PmP5C4YTyhU?usp=sharing>

Vanilla:

https://colab.research.google.com/drive/1-UgChQ_sH7H_E-4rFOsSEdX2MIGil-b?usp=sharing

TFT:

https://colab.research.google.com/drive/11pZ_uFf5Wd41TCrR4yj0NYV8NMjBIohg?usp=sharing

Autoformer:

<https://colab.research.google.com/drive/167n26KGhElB33LFySfie2WGHTN4bSb4A?usp=sharing>

5. Kaynaklar

- [1] data.ibb.gov.tr
- [2] https://huggingface.co/docs/transformers/model_doc/time_series_transformer
<https://www.databricks.com/blog/introduction-time-series-forecasting-generative-ai>.
- [3] <https://dergipark.org.tr/en/download/article-file/2296665>.
- [4] https://huggingface.co/docs/transformers/model_doc/bert.
- [5] <https://medium.com/i%CC%87stanbuldatascienceacademy/istdsa-b%C3%BClten-49-zaman-serilerinde-tahmin-modelleri-b82937d7b708>.
- [6] <https://miuul.com/blog/veri-biliminde-zaman-serileri>.
- [7] <https://medium.com/dataness-ai/understanding-temporal-fusion-transformer-9a7a4fcde74b>.